

ПРЕДСКАЗАНИЕ НИЗКИХ ОЦЕНОК ЗАКАЗОВ НА МАРКЕТПЛЕЙСЕ OLIST.

Capstone Project (3 поток Data Science в DataGroup.kz).

Спикер: Акмарал Кудайберген. [Ссылка на репозиторий в GitHub.](#)

БИЗНЕС-ПРОБЛЕМА И ЦЕЛЬ ПРОЕКТА.

- **Контекст:** Оценки 1-2 звезды ведут к оттоку клиентов и падению репутации платформы.
- **Цель:** Построить модель машинного обучения, которая предсказывает вероятность негативного отзыва до того, как клиент его оставит, чтобы бизнес мог проактивно решать проблему.
- **Задача:** Бинарная классификация (0 — хороший/нейтральный отзыв, 1 — плохой отзыв).


ДАННЫЕ И АРХИТЕКТУРА (SQL)

- **Источник:** Brazilian E-Commerce Public Dataset by Olist ([Kaggle](#)).
- **Подготовка данных:** Исходно 9 отдельных таблиц.
- **Решение:** Использование PostgreSQL (JOIN, CTEs, оконные функции, агрегации) для сборки единой аналитической витрины данных (95+ тыс. строк).
- **Визуал:** Можно вставить скриншот схемы БД (из файла olist_db_schema.png).




ИНСАЙТЫ ИЗ ДАННЫХ (EDA).

ПРОБЛЕМА ДИСБАЛАНСА: ПОКАЗАТЬ ГРАФИК РАСПРЕДЕЛЕНИЯ ЦЕЛЕВОЙ ПЕРЕМЕННОЙ (ОКОЛО 13% — ПЛОХИЕ ОТЗЫВЫ, 87% — ХОРОШИЕ). ПОЭТОМУ ACCURACY НЕ БУДЕТ ИСПОЛЬЗОВАТЬСЯ.




ГЛАВНЫЙ ИНСАЙТ: ГРАФИК ЗАВИСИМОСТИ ОЦЕНКИ ОТ ВРЕМЕНИ ДОСТАВКИ.



ПОДХОД К МАШИННОМУ ОБУЧЕНИЮ

- **Модели:** Logistic Regression (как baseline) и Random Forest.
- **Особенности обучения:**
 - Обработка пропусков и категориальных признаков (OneHotEncoder, Pipeline).
 - **Ключевой момент:** Использование `class_weight='balanced'` для борьбы с дисбалансом классов, чтобы модель не игнорировала недовольных клиентов.
- **Метрики:** Отказ от Accuracy в пользу ROC-AUC и F1-score (для миноритарного класса).
- Logistic Regression: Precision (класс 1 - плохой отзыв): 0.26 Recall (класс 1 - плохой отзыв): 0.55 F1-score (класс 1 - плохой отзыв): 0.36 ROC-AUC: 0.72.
- Random Forest: Precision (класс 1 - плохой отзыв): 0.34 Recall (класс 1 - плохой отзыв): 0.50 F1-score (класс 1 - плохой отзыв): 0.40 ROC-AUC: 0.74. Победитель!

Топ-10 самых важных факторов (Random Forest)



БИЗНЕС-РЕКОМЕНДАЦИИ

- **Управление ожиданиями:** Алгоритмам Olist стоит закладывать чуть больше времени в `estimated_delivery_days`, чтобы снизить процент "опозданий". Лучше привезти раньше обещанного, чем позже.
- **Оптимизация логистики:** Мониторинг продавцов и транспортных компаний с высокими тарифами (`freight_value`) и долгими сроками, так как они генерируют основной негатив.
- **Проактивная работа:** Использовать созданную ML-модель для выявления "заказов в зоне риска" и автоматической отправки извинений/промокодов клиентам до того, как они напишут гневный отзыв.